

Pré-Processamento de Dados

ESTAT0109 – Mineração de Dados em Estatística

Prof. Dr. Sadraque E. F. Lucena

sadraquelucena@academico.ufs.br

<http://sadraquelucena.github.io/mineracao>

Objetivo da Aula

- Dominar o pipeline de pré-processamento de dados

Por que Pré-Processar os Dados

- A qualidade de um modelo depende completamente da qualidade dos dados que utilizamos para construí-lo.
- Facilmente encontramos em bases de dados:
 - **Ruído** (*noisy*): Valores errados ou impossíveis (ex: um paciente com **IDADE** = 200 anos).
 - **Inconsistência** (*inconsistency*): A mesma informação registrada de formas diferentes (ex: **MUNICIPIO** = “Aracaju”, “Aracajú”).
 - **Heterogeneidade** (*heterogeneity*): Dados de múltiplas fontes, com formatos e chaves diferentes (ex: o código o município do Censo Escolar e do SIM usando padrões diferentes – 6 ou 7 dígitos).
 - **Dados faltantes** (*Missing*): O famoso **NA**.

Por que Pré-Processar os Dados

- O objetivo do pré-processamento de dados é **transformar dados brutos e “sujos” em um conjunto de dados limpo, coeso e de alta qualidade** que seja apropriado para a mineração.
- Antes de aplicar qualquer técnica de limpeza, transformação ou integração, precisamos fazer um diagnóstico. A primeira e mais fundamental etapa desse diagnóstico é entender a natureza dos nossos dados.
- Precisamos identificar os tipos de atributos (ou variáveis) que temos.

Tipos de Dados

Tipos de Dados

Todo conjunto de dados é composto por duas partes fundamentais, assim como uma planilha:

- **Objetos de Dados (as Linhas):** Representam a entidade que estamos observando.
 - Também chamados de: *amostras*, *instâncias*, *casos* ou *tuplas* (em bancos de dados).
 - Exemplos: um *paciente*, um *cliente*, um *município*, um *domicílio*.
- **Atributos (as Colunas):** Representam a característica ou propriedade que descreve o objeto.
 - Também chamados de: *dimensões*, *features* (em *Machine Learning*) ou *variáveis* (nosso termo preferido em Estatística).
 - Exemplos: **IDADE**, **SEXO**, **POPULACAO_2022**, **IDH_M**.
- Classificar os **tipos de atributos**, define quais técnicas estatísticas e de mineração podemos usar. Vejamos as classificações.

Tipos de Atributos

Nominal

- A ordem não importa.
- Exemplos: `ocupacao`(estatístico, médico, professor...), `COD_MUNICIPIO_IBGE` (ex: “2800308” = Aracaju).
- Um atributo nominal pode usar números (como `COD_MUN_IBGE` ou `ID_cliente`), mas operações matemáticas são sem sentido.
 - Não podemos calcular a “média” dos códigos de município.
 - A única medida de tendência central válida é a Moda (o valor mais frequente).

Tipos de Atributos

Binário (booleano)

- É um atributo nominal com apenas dois estados).
- Exemplos: **OBITO** (1=Sim, 0=Não), **FUMANTE** (1=Sim, 0=Não).
- **Subtipos Importantes:**
 - **Simétrico:** Ambos os estados têm o mesmo “peso”. Ex: **SEXO** (M/F).
 - **Assimétrico:** Um estado é mais “raro” ou “importante”. Ex: **TESTE_COVID** (Positivo=1, Negativo=0). Por convenção, o “1” é o resultado de maior interesse.

Tipos de Atributos

Ordinal

- Os valores têm uma **ordem ou ranking significativo**, mas a **magnitude (distância)** entre eles é desconhecida.
- Sabemos que Grande > Médio > Pequeno, mas não o quanto “Grande” é maior que “Médio”.
- Exemplos: **ESCOLARIDADE** (Analfabeto < Fundamental < Médio < Superior),
SATISFACAO_ATENDIMENTO: (Muito Ruim, Ruim, Neutro, Bom, Muito Bom).
- Estatísticas Válidas: **Moda e Mediana**. A Média ainda não faz sentido.

Tipos de Atributos

Quantitativo (Numérico)

São quantidades mensuráveis (números inteiros ou reais) onde as operações matemáticas (média, desvio padrão) fazem sentido. Há dois tipos:

1. **Intervalar (Interval-Scaled):** Tem ordem e as “distâncias” (intervalos) são iguais. O zero é apenas um ponto na escala, não significa ausência. Exemplos:
 - **Temperatura (°C / °F):** 0°C não é “ausência de temperatura”. Não podemos dizer que 20°C é “o dobro do calor” de 10°C.
 - **Datas (Ano):** O “Ano 0” não foi o começo do tempo.
 - **Operações:** Média, Mediana, Moda, Diferenças ($20^{\circ}\text{C} - 10^{\circ}\text{C} = 10^{\circ}\text{C}$).

Tipos de Atributos

Quantitativo (Numérico)

2. **Racional (Ratio-Scaled):** Tem ordem, distâncias iguais **E POSSUI UM “ZERO VERDADEIRO”**. O Zero (0) significa a ausência total da medida.

- **VL_TOTAL_INTERNACAO** (R\$ 0,00 é ausência de custo).
- **IDADE, PESO, ALTURA.**
- **RENDA_MENSAL, N_DE_FILHOS.**
- **Operações:** Todas! Média, Mediana, Moda, Diferenças E Rácios (R\$ 100 é exatamente o dobro de R\$ 50).

A Visão do *Machine Learning*

Muitas vezes, os algoritmos e softwares (como R e Python) simplificam a classificação em dois grandes grupos, que não são exatamente iguais aos anteriores, mas os englobam.

1. Atributo DISCRETO: Possui um conjunto de valores finito ou infinito contável (geralmente inteiros). Engloba:

- Nominal (ex: `RACA_COR`)
- Binário (ex: `OBITO`)
- Ordinal (ex: `ESCOLARIDADE`)
- Numéricos Inteiros (ex: `N_DE_FILHOS`, `DIAS_DE_INTERNACAO`).

A Visão do *Machine Learning*

2. **Atributo CONTÍNUO:** Possui um número infinito de valores “não contáveis” dentro de um intervalo (números reais, *floating-point*). Engloba atributos numéricos (Intervalares ou Racionais) que são medidos com casas decimais:

- PESO (ex: 75,32 kg)
- TAXA_MORTALIDADE_INFANTIL (ex: 12.4 por 1000)
- VL_MEDICAMENTO (ex: R\$ 150,75)

Pré-Processamento de Dados

Pré-Processamento de Dados

- Dados de entrada incorretos ou de baixa qualidade resultam inevitavelmente em saídas incorretas ou de baixa qualidade.
- Se não for tomado o devido cuidado em lidar adequadamente com questões de qualidade de dados antes de treinar um modelo, a saída do modelo será não confiável, enganadora ou simplesmente incorreta.

Objetivo: Arrumar os dados para iniciar uma análise de boa qualidade. Questões que temos que lidar:

1. Tratamento de Inconsistências
2. Valores Ausentes (*Missing Values*)
3. Ruído (*Noise*)
4. Integração de Dados (*Data Integration*)
5. Transformação de Dados (*Data Transformation*)
6. Redução de Dados (*Data Reduction*)

Vejamos detalhes de cada fase.

1. Tratamento de Inconsistências

1. Tratamento de Inconsistências

- Ocorre quando o mesmo dado é registrado de formas diferentes (sintaxe) ou quando um valor viola uma regra lógica (semântica).
- **Com identificar?**
 - **Para categorias:** Fazer uma tabela de frequência para avaliar há registros com sintaxe diferente (ex: `municipio` com respostas “Aracaju” e “Aracajú”).
 - **Para numéricos:** Obter mínimo, máximo e Boxplots para aver se há valores fora do possível (ex: `idade_da_mae` = 5 anos).
- **O que fazer:**
 - **Padronização de categorias:** Agrupar sinônimos ou erros de digitação em um único rótulo padrão (ex: “Aracajú”, “AJU”, “Aracaju” → “Aracaju”).
 - **Validação de regras:** Transformar valores inválidos em `NAs`.

2. Valores Ausentes (*Missing Values*, NAs)

2. Valores Ausentes (*Missing Values*, **NAs**)

Um **NA** pode ocorrer por 2 fatores principais:

a. Erro Aleatório:

- O digitador esqueceu; o paciente/cliente não quis informar.
- *Ação: Imputação.*

b. Erro Estrutural / “Não Aplicável”:

- *Ex (DATASUS):* **DATA_OBITO** está **NA** (porque o paciente está vivo).
- *Ex (CadÚnico):* **NOME_ESCOLA_FILHO** está **NA** (porque a família não tem filhos).
- *Ação: Não imputar!* O **NA** aqui é informação. Talvez criar uma categoria “Não Aplicável”.

Moral: Sempre leia o **Dicionário de Dados**!

2. Valores Ausentes (*Missing Values*)

Ao lidarmos com **NA**s, algumas estratégias costumam ser utilizadas:

- a. Remover a linha inteira se ela tiver algum **NA**;
- b. Substituir por uma constante;
- c. Substituir por uma medida de tendência central;
- d. Substituir pelo valor mais provável.

2. Valores Ausentes (*Missing Values*)

a. Remover a linha inteira se ela tiver algum **NA**

- Remover a linha inteira apenas se o **NA** ocorreu por acaso e se a perda for menor que 5% dos dados.
- Problema:
 - **Perda de Informação:** Se o **NA** estava só em **RACA_COR**, jogamos fora **IDADE**, **SEXO**, **MUNICIPIO** e o desfecho (a *label*).
 - **Viés de Seleção (PERIGO!):** E se os dados *não* estiverem faltando ao acaso?
 - *Exemplo:* Se só os mais ricos não responderam a renda e você **remove os mais ricos da sua análise**, o seu modelo se torna enviesado.

2. Valores Ausentes (*Missing Values*)

b. Substituir por uma constante

- NA em RENDA → 0
- NA em RACA_COR → "Desconhecido" ou "99"
- Problema:
 - O algoritmo pode erroneamente achar que “os NAs formam um conceito interessante”.
 - O modelo aprende que “Renda = 0” é um forte preditor, quando na verdade ele só significa “dato faltante”.
 - Isso distorce a distribuição dos dados (ex: cria um pico falso no “0”).

2. Valores Ausentes (*Missing Values*)

c. Substituir por uma medida de tendência central

Substitui o **NA** pela medida “do meio” da distribuição daquele atributo. * **A Regra de Ouro:** * **Média:** Usar se a distribuição for **simétrica** (ex: **IDADE**, se for normal). * **Mediana:** Usar se a distribuição for **assimétrica** (ex: **RENDIA**). * **Vantagem:** É rápido e preserva a média/mediana geral. * **Desvantagem:** Ignora as relações entre variáveis e “achata” a **variância** (subestima a variabilidade real).

2. Valores Ausentes (*Missing Values*)

d. Substituir pelo valor mais provável

Esta é a abordagem moderna e preferida na maioria dos casos. Trata o valor ausente como um problema de predição.

- **Conceito:** Usamos os outros atributos (x_1, x_2, x_3) para *prever* o valor faltante (Y_{na}).
- **Como?**
 - **Regressão:** Para prever **RENDA** (numérico) usando **IDADE** e **ESCOLARIDADE**.
 - **Árvore de Decisão / k-NN:** Para prever **RACA_COR** (categórico) usando **MUNICIPIO** e **RENDA**.
 - *No R:* Pacotes como **recipes** (Tidymodels) ou **mice** fazem isso.
- **Vantagem:** Usa a maior parte da informação dos dados presentes e preserva as relações entre os atributos.

3. Ruído (*Noise*)

3. Ruído (*Noise*)

Ruído é um erro aleatório ou variância em uma variável medida.

- Não é um **NA**, mas um valor que parece “deslocado”.
- **Exemplo (SIH/DATASUS):**
 - Uma internação por apendicite (**VL_TOTAL**) com custo de R\$ 1,50.
 - Uma internação com custo de R\$ 5.000.000,00 (enquanto a média é R\$ 2.000,00).
- **Objetivo:** “Suavizar” (*smooth*) esses dados para remover a variação aleatória sem perder o sinal verdadeiro.

3. Ruído (*Noise*)

Técnica 1: *Binning* (Agrupamento ou Discretização)

Binning é uma técnica de *suavização local* (olha a “vizinhança”).

O Processo (Ex: **VALOR_INTERNACAO**):

1. Ordenar os dados: [4, 8, 15, 21, 21, 24, 25, 28, 34]
2. Particionar em “Bins” (Balde):
 - Ex: Bins de frequência igual (tamanho 3)
 - Bin 1: [4, 8, 15]
 - Bin 2: [21, 21, 24]
 - Bin 3: [25, 28, 34]
3. Substituir (Suavizar): Aplicar uma regra ao bin.

3. Ruído (*Noise*)

Tipos de Suavização por *Binning*

Usando o exemplo (Bin 1: [4, 8, 15]):

- 1. Suavização pela MÉDIA:** * O que faz: Substitui todos os valores pela média do bin. * Ex: Média(4, 8, 15) = 9 * Resultado: [9, 9, 9]
- 2. Suavização pela MEDIANA:** (Muito recomendado!) * O que faz:** Substitui todos pela mediana do bin (robusto a *outliers*!). * Ex: Mediana(4, 8, 15) = 8 * Resultado: [8, 8, 8]
- 3. Suavização pelos LIMITES:** * O que faz: Substitui cada valor pelo limite (min/max) mais próximo. * Ex: [4, 8, 15] -> [4, 4, 15] (8 está mais perto de 4 do que de 15)

3. Ruído (*Noise*)

Técnica 2 e 3: Regressão e Análise de *Outliers*

O *Binning* não é a única forma de suavizar dados.

Regressão: Ajusta os dados a uma função (ex: uma linha de regressão linear). * **Como suaviza?** O “ruído” é a variação aleatória (o erro, ϵ) ao redor da linha. O valor “suavizado” é o valor *predito* pela linha.

Análise de *Outliers* (via Clustering): Agrupa dados similares (clusters). * **Como suaviza?** Valores que caem fora dos clusters podem ser considerados *outliers* (ruído).

4. Integração de Dados (*Data Integration*)

4. Integração de Dados (*Data Integration*)

É o processo de combinar dados de múltiplas fontes.

O Desafio: Os dados *nunca* vêm de uma única fonte limpa. * Queremos cruzar **Taxas de Mortalidade (SIM/DATASUS)**... * ... com **Indicadores Socioeconômicos (Censo/IBGE)**... * ... com **Dados de Escolaridade (CadÚnico)**... * ... para cada Município de Sergipe.

Temos quatro grandes desafios ao fazer isso. Vejamos.

4. Integração de Dados (*Data Integration*)

Desafio 1: O Problema da Identificação da Entidade

Como o computador sabe que ‘Aracaju’ é ‘Aracaju’?

- **Definição:** Como parear entidades do mundo real (pacientes, municípios, clientes) que estão em bases diferentes?
- **Ex:** `id_cliente` (Base A) vs. `numero_client` (Base B).

Exemplo: * Base IBGE (Censo): O código de Aracaju é `CD_MUN_IBGE` = “2800308” (7 dígitos). * Base DATASUS (SIH): O código de Aracaju é `CD_MUN_DATASUS` = “280030” (6 dígitos). * **Solução:** Não dá para juntar direto! Precisamos transformar `CD_MUN_IBGE` para criar uma chave compatível com `CD_MUN_DATASUS`.

4. Integração de Dados (*Data Integration*)

Desafio 2: Conflito de Valores

Ok, conseguimos fazer o `join()` pelo código do município. Agora o problema é outro: **os valores não “falam” a mesma língua.**

Causas (do Texto):

1. Diferença de Escala/Unidade: (O mais comum!)

- *Base A (IBGE): RENDA* em “Salários Mínimos”.
- *Base B (CadÚnico): RENDA_PER_CAPITA* em “Reais (R\$)”.
- *Base C (World Bank): GDP* em “Dólares (USD)”.

2. Diferença de Abstração:

- *Base A (SIH): VL_TOTAL_INTERNACAO* (nível do paciente).
- *Base B (CNES): ORCAMENTO_ANUAL_HOSPITAL* (nível da unidade).

3. Diferença de Semântica:

- *Base A: INDICE_ESCOLARIDADE* (População > 18 anos).
- *Base B: INDICE_ESCOLARIDADE* (População > 25 anos).

4. Integração de Dados (*Data Integration*)

Desafio 3: Redundância (“Informação Repetida”)

Um atributo que pode ser “derivado” de outros.

- **Exemplo:**

- Você baixa uma tabela que tem as colunas:

- `POP_TOTAL`

- `POP_URBANA`

- `POP_RURAL`

- **Problema:** `POP_TOTAL` é redundante (é `POP_URBANA` + `POP_RURAL`).

- **Por que é ruim?**

- Aumenta a dimensionalidade (Maldição da Dimensionalidade).

- Viola premissas de alguns modelos (ex: Multicolinearidade em Regressão).

- Dá peso duplicado a uma mesma informação em algoritmos de distância (K-means).

4. Integração de Dados (*Data Integration*)

Como Detectar Redundância? Com Estatística!

Para Atributos NUMÉRICOS (ex: **POP_TOTAL** vs **POP_URBANA**): * Coeficiente de Correlação (Pearson) * `cor(dados$pop_total, dados$pop_urbana)` * Se r for muito alto (ex: > 0.9), há forte suspeita de redundância. * Covariância

Para Atributos NOMINAIS (Categóricos): * Teste χ^2 (Qui-Quadrado) * `chisq.test(table(dados$var1, dados$var2))` * Mede a independência. Se p -valor for baixo (ex: < 0.05), as variáveis são *dependentes*, o que pode indicar redundância (ex: **COD_MUNICIPIO** e **NOME_MUNICIPIO** são 100% dependentes).

4. Integração de Dados (*Data Integration*)

Desafio 4: Duplicação de linhas

A mesma entidade (linha) aparece mais de uma vez.

- **Exemplo:** O mesmo cliente ("**João da Silva**") aparece duas vezes na tabela de compras, uma com endereço “Rua A” e outra com “Rua B” (pois ele se mudou e a base não foi atualizada corretamente).
- **Exemplo:**
 - **Record Linkage (Ligação de Registros)**
 - A paciente **MARIA JOSE DA SILVA** (do CadÚnico) é a *mesma* paciente **M J SILVA** (do SINAN/Dengue)?
- **Problema:** Gera inconsistências e superestima contagens.
- **Solução:** Requer técnicas avançadas (ex: *fuzzy matching*) para encontrar duplicatas “prováveis” e consolidá-las. (Isso dá um ótimo TCC com o Prof. Sadraque!)

5. Transformação de Dados (*Data Transformation*)

5. Transformação de Dados (*Data Transformation*)

- Frequentemente é preciso modificar a estrutura ou características dos dados para formas “apropriadas para a mineração”.
- Algumas técnicas usadas são:
 - a. Normalização Z-score;
 - b. Discretização Min-Max;
 - c. Transformação logarítmica;
 - d. Discretização;
 - e. Codificação de variáveis *dummy*.

5. Transformação de Dados (*Data Transformation*)

a. Normalização Z-score

- Conhecida como *normalização z-score* ou *normalização de média zero*.
- Esta abordagem resulta em valores com média 0 e variância 1.
- A variável normalizada v' é dada por

$$v' = \frac{v - \bar{v}}{\sigma_v},$$

em que v é a variável original, \bar{v} é a média da variável v e σ_v é o desvio padrão da variável v .

Quem Precisa Disso?

- **K-Means** (Clusterização), **K-Nearest Neighbors (K-NN)** (Classificação), **SVM** (Classificação), **Redes Neurais**, **PCA** (Redução de Dimensionalidade).

Basicamente, qualquer algoritmo baseado em distância!

5. Transformação de Dados (*Data Transformation*)

b. Normalização Min-Max

- Mapeia linearmente os valores para um novo intervalo, geralmente $[0, 1]$, usando:

$$v'_i = \frac{v_i - \min_A}{\max_A - \min_A} \times (\text{novo_max} - \text{novo_min}) + \text{novo_min}$$

(Para $[0, 1]$, os dois últimos termos desaparecem).

Exemplo (RENDa):

- $v = 700$, $\min = 200$, $\max = 2000$
- $v' = (700 - 200)/(2000 - 200) = 500/1800 = 0.277$
- **Vantagem:** Preserva as relações lineares.
- **Desvantagem:** Extremamente sensível a outliers! Um único valor de Renda de R\$ 50.000 (um erro) “espremeria” todos os outros dados perto de 0.

5. Transformação de Dados (*Data Transformation*)

Atenção!!!

NUNCA ajuste seus parâmetros de normalização (min/max ou z-score) usando os dados de **TREINO E TESTE** juntos!

Isto é um *vazamento de dados* (*data leakage*). Você estaria “contando” ao seu modelo de treino sobre a distribuição do futuro (teste).

O Processo Correto (Pipeline):

1. Divida os dados: **Treino e Teste**.
2. Calcule os parâmetros (ex: `mean()`, `sd()`) **APENAS** no conjunto de **Treino**.
3. Aplique esses mesmos parâmetros em **ambos** (Treino e Teste).
4. No R (Tidymodels), o `recipe()` + `step_normalize()` faz isso automaticamente!

5. Transformação de Dados (*Data Transformation*)

c. Transformação logarítmica

- As transformações anteriores são boas quando os dados são simétricos.
- A transformação logarítmica é mais adequada para distribuições assimétricas e dados com valores que variam amplamente em magnitude.
- A transformação é

$$v' = \log(v).$$

5. Transformação de Dados (*Data Transformation*)

d. Discretização

- A *discretização* consiste em transformar variáveis contínuas em categóricas.
- Alguns algoritmos exigem que a variável independente seja binária ou tenha um número limitado de valores distintos.
- Esse processo pode ser feito usando a suavização com médias de intervalo ou suavização com limites de intervalo.
- Outra forma comum é a *dicotomização*.
 - Exemplo: Os valores {4, 8, 9, 15, 21, 21, 24, 25, 26, 28, 29, 34} seriam dicotomizados usando 20 como valor de corte, ficando {0, 0, 0, 0, 1, 1, 1, 1, 1, 1, 1, 1}.

5. Transformação de Dados (*Data Transformation*)

e. Codificação de variáveis *dummy*

- Uma variável *dummy* é uma dicotomização de uma variável contínua.
- Ela é muito usada em algoritmos que exigem que os atributos independentes sejam numéricos (como regressão ou k-NN) e como uma forma de representar dados ausentes.
- Suponha que temos a variável abaixo:

Escolaridade	Código
<i>Enino Fundamental</i>	1
<i>Ensino Médio</i>	2
<i>Ensino Superior</i>	3

5. Transformação de Dados (*Data Transformation*)

e. Codificação de variáveis *dummy*

- Usando uma variável dummy completa, temos:

Escolaridade	Ensino Médio	Ensino Superior
<i>Ensino Fundamental</i>	0	0
<i>Ensino Médio</i>	1	0
<i>Ensino Superior</i>	0	1

- Agora, ao invés de uma variável, temos 2 variáveis *dummies*.
- Em geral, o número de variáveis *dummies* criadas é $n - 1$, em que n é o número de categorias da variável original.
- Em geral, a categoria que não virou *dummy* é porque ela é, de alguma forma, menos importante para o estudo.

6. Redução de Dados (*Data Reduction*)

6. Redução de Dados (*Data Reduction*)

O Objetivo: Reduzir o número de colunas (k) de d para k (onde $k < d$), preservando o máximo de “sinal” e removendo “ruído”.

Três Estratégias Principais:

1. Projeção Linear (PCA - Principal Components Analysis):

- **O que faz:** Combina atributos correlacionados para criar *novos* eixos (Componentes Principais) que capturam o máximo de variância dos dados.
- **Resultado:** Um *novo* dataset (ex: $k = 5$) onde cada coluna é uma combinação linear das originais (ex: $d = 50$).

6. Redução de Dados (*Data Reduction*)

2. Seleção de Atributos (Attribute Subset Selection):

- **O que faz:** Remove atributos irrelevantes ou redundantes. *Não cria* novas colunas.
- **Como:** Métodos *greedy* (Heurísticos) como *Forward Selection* (adiciona o melhor) ou *Backward Elimination* (remove o pior).
- **Resultado:** Um *subconjunto* do dataset original (ex: $k = 10$ das $d = 50$ colunas originais).

3. Mapeamento Não Linear (ex: t-SNE, Kernel PCA):

- **O que faz:** (Para quando o PCA falha). Mapeia os dados de alta dimensão para baixa dimensão (ex: $k = 2$ ou $k = 3$) **preservando a estrutura de vizinhança** (proximidade).
- **Resultado:** Essencial para *visualizar* clusters complexos que são “emaranhados” nos dados originais.

Agora vamos fazer no R...

Fim

